

Arquitetura de Agentes de IA com Cloud Code (Visão Técnica)

1. Visão Geral

Este documento descreve a arquitetura moderna de sistemas de atendimento automatizado com Inteligência Artificial, utilizando Cloud Code, agentes autônomos, memória e ferramentas externas. O objetivo é permitir que um sistema converse com usuários, interprete solicitações, execute ações e registre dados de forma automática.

2. Camada de Entrada

A entrada do sistema geralmente ocorre por canais de comunicação como WhatsApp, chat em site ou formulários. Mensagens recebidas são enviadas via webhook para o servidor cloud, que inicia o processamento.

3. Servidor na Nuvem

A infraestrutura cloud hospeda toda a lógica do sistema. É responsável por receber requisições, executar Cloud Code, consultar banco de dados, chamar APIs de IA e retornar respostas ao usuário. Provedores comuns incluem AWS, Google Cloud e DigitalOcean.

4. Cloud Code (Motor de Fluxo)

O Cloud Code substitui ferramentas visuais de automação. Em vez de blocos visuais, a lógica do fluxo é programada diretamente em código. Esse código controla estados da conversa, valida dados e decide próximos passos.

5. Inteligência Artificial

Modelos de linguagem processam as mensagens do usuário e geram respostas naturais. Eles também ajudam a identificar intenções, coletar dados e orientar o fluxo de atendimento.

6. Ferramentas (Tools)

Agentes de IA podem executar ferramentas programadas no sistema. Exemplos incluem: - consultar boletos - abrir chamados de manutenção - agendar reuniões - consultar cadastro de clientes Essas ferramentas conectam a IA com sistemas reais.

7. Memória e Contexto

Para manter conversas coerentes, o sistema precisa armazenar histórico de mensagens e dados do usuário. Memória pode ser de curto prazo (conversa atual) ou longo prazo (informações persistentes do cliente).

8. Base de Conhecimento (RAG)

A técnica de Retrieval Augmented Generation permite que a IA consulte documentos antes de responder. Isso melhora a precisão e reduz respostas incorretas.

9. Banco de Dados

O banco armazena dados operacionais do sistema: - cadastro de clientes - histórico de conversas - status de atendimento - informações coletadas durante o fluxo

10. Filas e Escalabilidade

Sistemas em produção utilizam filas de processamento para evitar sobrecarga. As mensagens entram em uma fila e são processadas por workers, permitindo escalabilidade.

11. Monitoramento e Logs

Ferramentas de monitoramento registram erros, uso de APIs e métricas de desempenho. Isso permite detectar falhas rapidamente e otimizar o sistema.

12. Segurança e LGPD

Sistemas que manipulam dados pessoais devem aplicar práticas de segurança, como criptografia, autenticação de API e conformidade com a legislação de proteção de dados.

13. Exemplo de Arquitetura Completa

Cliente → API de Mensagem → Webhook → Fila → Servidor Cloud → Cloud Code → IA → Ferramentas → Banco de Dados → Resposta.